



UNIVERSIDAD DE BUENOS AIRES
FACULTAD DE CIENCIAS EXACTAS Y NATURALES
DEPARTAMENTO DE COMPUTACIÓN

[**acá va tu título**]

Tesis de Licenciatura en Ciencias de la Computación

Rafael Romani

Director: [**acá va tu director**]

Codirector: [**acá va tu codirector**]

Buenos Aires, 2026

[ACÁ VA TU TITULO]

[Acá va el resumen]

Palabras claves: [acá van las palabras clave]

[acá van los agradecimientos]

Índice general

En este trabajo se van a definir los transformers como ¿máquinas aceptadoras?. Un transformer consta de una cinta de n_{max} celdas de la que lee el input (escrito en las primeras n celdas) y va escribiendo a derecha de lo ya escrito nuevos caracteres usando un generador de tokens.

¿Cuál sería la p
bra correcta?

El generador de tokens está compuesto por 4 partes: una función de token embedding (TE), una función de codificación posicional (PE), L capas de decodificación y una capa final de output. Se define L como la profundidad del transformer. Cada capa de decodificación está compuesta por dos subcapas: una capa de atención (ATTN) y una red de propagación hacia adelante totalmente conectada por posiciones (*a position-wise fully-connected feed-forward network*) (FF).

Cada transformer opera sobre un alfabeto Σ y está definido por los parámetros $\theta = (\theta_{TE}, \theta_{PE}, \{\theta_{ATTN}^{(l)}, \theta_{FF}^{(l)}\}_{l=0}^{L-1}, \theta_{output})$.

¿Un comentario
sobre que θ es l
que se entrena?

El modelo estudiado en este trabajo es no uniforme, es decir que para palabras de distintas longitudes se utilizan distintos transformers.

Token embedding: es un mapeo de los elementos de Σ a vectores de $\mathbb{R}^d$. El mapeo está definido por $\theta_{TE} \in \mathbb{R}^{d \times |\Sigma|}$. Para todo $a \in \Sigma$ se va a notar $\theta_{TE}(a) \in \mathbb{R}^d$ al mapeo del caracter a .

Codificación posicional: es un mapeo de las posiciones de la cinta a vectores de $\mathbb{R}^d$. El mapeo está definido por $\theta_{PE} \in \mathbb{R}^{d \times n_{max}}$. Para todo $1 < i \leq n_{max}$ se va a notar $\theta_{PE}(i) \in \mathbb{R}^d$ al mapeo de la posición i .

Capa de atención: dados los parámetros $\theta_{ATTN} = (W_Q, W_K, W_V, W_O) \in \mathbb{R}^d \times \mathbb{R}^d \times \mathbb{R}^d \times \mathbb{R}^d$ la capa de atención se define como el mapeo definido en el algoritmo ?? de $\mathbb{R}^d \times \dots \mathbb{R}^d$ a $\mathbb{R}^d \times \dots \mathbb{R}^d$.

[Acá viene el algoritmo 1 de toyota]

¿Cómo noto qu
son n vectores c
 $\mathbb{R}^d$?

Capa de feed forward?: dado $\theta_{FF} = (W_1, b_1, W_2, b_2) \in \mathbb{R}^{d \times d} \times \mathbb{R}^d \times \mathbb{R}^{d \times d} \times \mathbb{R}^d$, se define la capa de feed forward como un mapeo de $\mathbb{R}^d$ a $\mathbb{R}^d$ dado por la siguiente ecuación $FF_{\theta_{FF}} := W_2 \text{softmax}(W_1 h + b_1) + b_2$. Donde $\text{softmax} : \mathbb{R}^d \rightarrow \mathbb{R}^d$ reemplazando cada coordenada por el máximo entre su valor y 0: $\text{relu}(h)_i = \max(h_i, 0)$ para todo $0 < i \leq d$.

ver cómo copiar

Output: dado $\theta_{output} \in \mathbb{R}^{|\Sigma| \times d}$ la capa de output se define como un mapeo de $\mathbb{R}^d$ a una distribución de probabilidad sobre Σ . Para todo $h \in \mathbb{R}^d$ el mapeo se computa como $\text{softmax}(\theta_{output} h)$.

Hay que ver cómo
nombrar esta ca